

Máster Universitario en Ciencia y Tecnología Informática
2025-2026

Trabajo Fin de Máster

“Evaluación asistida de actividades del lenguaje mediante modelos de inteligencia artificial.”

Álvaro Marco Pérez

Tutor

David Quintana Quintero

Leganés, Junio 2026

DETECCIÓN DEL PLAGIO

La Universidad utiliza el programa **Turnitin Feedback Studio** para comparar la originalidad del trabajo entregado por cada estudiante con millones de recursos electrónicos y detecta aquellas partes del texto copiadas y pegadas. Copiar o plagiar en un TFM es considerado una **Falta Grave**, y puede conllevar la expulsión definitiva de la Universidad.



Esta obra se encuentra sujeta a la licencia Creative Commons **Reconocimiento - No Comercial - Sin Obra Derivada**

RESUMEN

Palabras clave:

DEDICATORIA

ÍNDICE GENERAL

1. INTRODUCCIÓN.	1
1.1. Estructura del documento	1
1.2. Contexto y motivación.	1
1.2.1. Contexto	2
1.2.2. Motivación	2
1.3. Problema de investigación y objetivos	2
1.3.1. Preguntas de investigación	2
1.3.2. Objetivos específicos.	4
2. ESTADO DE LA CUESTIÓN	5
2.1. Conceptos previos	5
2.2. Evaluación automática de lenguaje	6
2.3. Evaluación automática del habla	7
2.4. Sistemas híbridos y enfoques basados en recuperación de información.	8
3. METODOLOGÍA	10
3.1. Diseño experimental	10
3.2. Datos utilizados	10
3.3. Métricas de evaluación.	10
4. DISEÑO DEL SISTEMA.	11
4.1. Arquitectura general	11
4.2. Módulos de evaluación	11
4.3. Implementación	11
5. EXPERIMENTOS.	12
5.1. Configuración experimental	12
5.1.1. Experimento 1	12
5.1.2. Experimento 2...	12
5.2. Comparación de modelos	12
5.2.1. Experimento 1	12
5.2.2. Experimento 2...	12

5.3. Evaluación de consistencia	12
5.3.1. Experimento 1	12
5.3.2. Experimento 2...	12
6. RESULTADOS Y DISCUSIÓN	13
6.1. Experimento 1	13
6.1.1. Resultados	13
6.1.2. Discusión	13
6.2. Experimento 2...	13
7. CONCLUSIONES	14
7.1. Resumen de aportaciones	14
7.2. Respuesta a las preguntas de investigación	14
7.3. Trabajo futuro	14
BIBLIOGRAFÍA	

ÍNDICE DE FIGURAS

ÍNDICE DE TABLAS

1. INTRODUCCIÓN

1.1. Estructura del documento

Este documento está dividido en varios capítulos que se centrarán en diversos aspectos del desarrollo, metodología y resultados de este trabajo de fin de estudios.

En el capítulo 1. Introducción se desarrollan los conceptos relacionados con el preámbulo que justifica el desarrollo de este trabajo. Se abordarán el contexto y motivación del alumno, así como las preguntas de investigación y los objetivos específicos esperados.

En el capítulo 2. Estado de la cuestión se abordará el conocimiento científico existente relacionado con la materia de este TFM. También se abordará los conceptos necesarios para la comprensión del trabajo dentro de su contexto.

En el capítulo 3. Metodología se recogerán las fases del diseño que da lugar al experimento, la procedencia y características de los datos utilizados y las métricas utilizadas para la evaluación estadística de los resultados.

En el capítulo 4. Diseño del sistema se abordará en detalle la arquitectura de software donde se han realizado los experimentos.

En el capítulo 5. Experimentos se recojen cada una de las configuraciones de los modelos desarrollados en la experimentación. Se evaluará el desempeño de cada uno de ellos así como su consistencia.

Análogamente, en el capítulo 6. Resultados y discusión se presentarán cualitativa y cuantitativamente los resultados obtenidos en los distintos experimentos. También se discutirán las limitaciones de los resultados.

Finalmente, en el capítulo 7. Conclusiones, se reflexionará acerca de las aportaciones de este trabajo, se responderán las preguntas de investigación planteadas y se introducirán brevemente las posibles líneas de trabajo futuro.

Añadido a esto, se podrá encontrar como secciones independientes, los anexos y bibliografía del documento.

1.2. Contexto y motivación

En este apartado se aclarará el contexto sobre el cual se cimenta este trabajo de fin de estudios, así como las características que han motivado su desarrollo.

1.2.1. Contexto

El desarrollo del proyecto de evaluación asistida en actividades lingüísticas se realiza dentro de la empresa Smile and Learn Digital Creations. Smile and Learn es una empresa consolidada en el sector educativo digital que dedica su actividad al desarrollo de actividades y herramientas educativas para centros de educación primaria, tanto en el ámbito nacional como internacional.

El desarrollo reflejado en este trabajo de fin de grado se contextualiza dentro de uno de sus productos más novedosos, Ainara, una plataforma de creación de contenido personalizado orientada al profesorado. Más concretamente como un tipo de actividad independiente ofertada dentro del catálogo del producto.

1.2.2. Motivación

La realización de este trabajo de fin de estudios está motivado por la posibilidad de realizar un proyecto de investigación aplicada al ámbito laboral. Esto no solo presenta los retos habituales en un proyecto académico, como la complejidad de mantener un estándar de calidad en metodología, experimentación y análisis de los resultados. Sino además los asociados a la adecuación en un entorno preexistente en producción, la exposición del desarrollo a usuarios con conocimientos variables y el ajuste en tiempo de desarrollo y presupuesto dedicado.

1.3. Problema de investigación y objetivos

En esta sección se abordan las preguntas de investigación y objetivos específicos de este trabajo con el objetivo de describir la naturaleza del mismo, así como los límites de su alcance dentro del ámbito de la evaluación automática de actividades de lingüística.

1.3.1. Preguntas de investigación

Definición de las preguntas de investigación que guían el desarrollo del trabajo. En este apartado elegir preliminarmente en función de cuando de medibles, acotadas y alineadas con el desarrollo. Preguntas obtenidas de AIG:

1. 1. Fiabilidad y calidad de evaluación

- RQ1: ¿En qué medida los modelos de lenguaje de gran escala son capaces de evaluar automáticamente respuestas en lenguaje natural de forma consistente y fiable?
- RQ2: ¿Qué grado de concordancia presentan las evaluaciones generadas por LLMs frente a métricas objetivas o criterios predefinidos?

- RQ3: ¿Qué variabilidad presentan las evaluaciones de un mismo modelo ante múltiples ejecuciones con la misma entrada?
2. 2. Comparación de modelos y estrategias
- RQ4: ¿Existen diferencias significativas en el rendimiento de distintos LLMs en tareas de evaluación automática del lenguaje?
 - RQ5: ¿Cómo afectan distintas estrategias de prompting (zero-shot, few-shot, chain-of-thought) a la calidad de la evaluación generada?
 - RQ6: ¿Qué impacto tiene el uso de contexto adicional (por ejemplo, enunciados, soluciones de referencia o rúbricas) en la precisión de la evaluación?
3. 3. Arquitecturas híbridas y mejoras
- RQ7: ¿Mejora la calidad de la evaluación al combinar LLMs con técnicas tradicionales de análisis lingüístico?
 - RQ8: ¿Qué ventajas presentan los enfoques híbridos frente a los basados únicamente en LLMs en términos de interpretabilidad y robustez?
 - RQ9: ¿En qué medida la incorporación de módulos especializados (gramática, semántica, pronunciación) contribuye a mejorar el rendimiento global?
4. 4. Evaluación de respuestas habladas
- RQ10: ¿Cómo afecta la calidad de la transcripción automática (ASR) a la evaluación final de respuestas orales?
 - RQ11: ¿Qué aspectos del habla (fluidez, pronunciación, prosodia) pueden ser evaluados de forma fiable mediante modelos automáticos?
5. 5. Explicabilidad y utilidad del sistema
- RQ12: ¿Son las explicaciones generadas por los LLMs comprensibles y útiles como feedback educativo?
 - RQ13: ¿En qué medida los modelos son capaces de justificar sus evaluaciones de forma coherente y consistente?
6. 6. Robustez y limitaciones
- RQ14: ¿Cómo se comportan los modelos ante respuestas ambiguas, incompletas o incorrectas?
 - RQ15: ¿Qué tipos de errores son más frecuentes en la evaluación automática (por ejemplo, sobrevaloración, infravaloración, falta de coherencia)?
7. 7. Eficiencia y viabilidad
- RQ16: ¿Cuál es el coste computacional de los distintos enfoques y su viabilidad en entornos reales?

- RQ17: ¿Es viable el uso de estos sistemas en contextos educativos sin intervención humana?

1.3.2. Objetivos específicos

Descripción detallada de los objetivos técnicos y experimentales.

2. ESTADO DE LA CUESTIÓN

2.1. Conceptos previos

¿Introduzco un capítulo/sección 'Conceptos previos' que haga una introducción a los conceptos sobre los que se cimenta este trabajo? P.e.: Inteligencia Artificial, LLMs y otro tipo de conceptos de imprescindible conocimiento para la comprensión del trabajo.

Qué incluir:

- Lenguaje natural y evaluación
- Qué es el lenguaje natural (texto y habla)

Qué implica “evaluar lenguaje”:

- forma (gramática, ortografía)
- contenido (semántica, adecuación)
- pragmática (intención, contexto)
- Modelos de lenguaje (LLMs)
- Definición de LLM

Capacidades:

- generación
- comprensión
- evaluación (emergente)
- Idea clave: Los LLMs no fueron diseñados explícitamente para evaluar, pero muestran capacidad para hacerlo

ASR (Automatic Speech Recognition)

- Qué es
- Pipeline básico:
- audio → texto

Problemas:

- ruido
- acentos
- niños (importante para tu contexto)

Cierre del apartado: Introduce la idea de que evaluar lenguaje automático implica múltiples niveles → necesidad de enfoques complejos

2.2. Evaluación automática de lenguaje

Revisión de técnicas de Automated Essay Scoring y Automatic Short Answer Grading. Revisión de los artículos académicos relacionados con el análisis y evaluación de lenguaje escrito.

2.2.1 Automated Essay Scoring (AES) Qué explicar:

- Evaluación automática de textos largos
- Métodos tradicionales:
 - features lingüísticas (longitud, vocabulario)
 - modelos supervisados

Problemas:

- poca interpretabilidad
- dependencia de datasets anotados
- dificultad con contenido semántico

Transición a LLMs:

- LLMs permiten evaluar coherencia y generar feedback

Pero:

- riesgo de inconsistencia
- falta de control

2.2.2 Automatic Short Answer Grading (ASAG) Qué incluir:

- evaluación de respuestas cortas

- comparación con respuestas de referencia

Métodos:

- similitud semántica
- embeddings
- modelos supervisados

Problemas:

- múltiples respuestas correctas
- ambigüedad

2.3. Evaluación automática del habla

Métodos de evaluación de pronunciación, fluidez y prosodia mediante técnicas de procesamiento del habla. Revisión de los artículos académicos y los sistemas existentes con el análisis y evaluación de las características del habla. Qué evaluar en habla:

- pronunciación
- fluidez
- ritmo (prosodia)

Métodos clásicos:

- análisis acústico
- modelos fonéticos

Problemas:

- alta variabilidad
- dependencia del idioma
- dificultad con niños (clave si lo quieres mencionar indirectamente)

Conexión con LLMs:

- LLM no trabaja directamente con audio
- depende de ASR

Idea clave -> la evaluación de habla se convierte en evaluación de texto + pérdida de información

2.4. Sistemas híbridos y enfoques basados en recuperación de información

Descripción de aproximaciones que combinan modelos lingüísticos, técnicas tradicionales y recuperación de información. Revisión de los artículos académicos orientados al uso de sistemas de evaluación con recuperación de información y recomendaciones.

2.4.1 Sistemas híbridos Qué son:

- combinación de:
 - reglas lingüísticas
 - modelos clásicos
 - LLMs

Ventajas:

- mayor control
- más interpretabilidad
- menor dependencia del modelo

Ejemplo aplicado: corrector gramatical + LLM evaluador

2.4.2 RAG (Retrieval-Augmented Generation) Qué explicar:

- uso de información externa
- mejora de contexto

Aplicación en evaluación:

- enunciado
- solución modelo
- rúbrica

Ventajas:

- reduce alucinaciones
- mejora precisión

Problemas:

- complejidad

- dependencia de datos externos

2.4.3 LLMs como evaluadores (LLM-as-a-judge) Qué explicar:

- uso de LLMs para evaluar texto

Problemas identificados en literatura:

- sesgo
- inconsistencia
- sensibilidad al prompt

Conexión con tu TFM ->Tu trabajo analiza precisamente estos problemas

CIERRE DEL ESTADO DEL ARTE Debes terminar con algo así Hueco de investigación

- existen muchos trabajos en:
 - AES
 - ASAG
 - LLMs

Pero, faltan enfoques que:

- combinen evaluación modular
- analicen consistencia
- integren texto + habla
- evalúen fiabilidad sin datasets grandes

Posicionamiento de tu TFM ->Este trabajo propone un marco modular basado en LLMs para la evaluación automática del lenguaje, analizando su fiabilidad, consistencia y comportamiento bajo distintas configuraciones.

3. METODOLOGÍA

3.1. Diseño experimental

Descripción del enfoque experimental adoptado para evaluar los modelos y estrategias.

3.2. Datos utilizados

Descripción de los datasets o corpus empleados en el proyecto.

3.3. Métricas de evaluación

Definición de las métricas utilizadas para evaluar los resultados (correlación, error medio, consistencia, etc.).

4. DISEÑO DEL SISTEMA

4.1. Arquitectura general

Descripción de la arquitectura del sistema desarrollado.

4.2. Módulos de evaluación

Descripción de los distintos componentes encargados de analizar las respuestas.

4.3. Implementación

Tecnologías utilizadas y detalles de implementación del prototipo experimental.

5. EXPERIMENTOS

5.1. Configuración experimental

Parámetros, modelos y configuraciones evaluadas.

5.1.1. Experimento 1

5.1.2. Experimento 2...

5.2. Comparación de modelos

Evaluación comparativa entre distintos modelos o estrategias.

5.2.1. Experimento 1

5.2.2. Experimento 2...

5.3. Evaluación de consistencia

Análisis de estabilidad y repetibilidad de los resultados.

5.3.1. Experimento 1

5.3.2. Experimento 2...

6. RESULTADOS Y DISCUSIÓN

Repetir esto por cada uno de los experimentos que tenga

6.1. Experimento 1

6.1.1. Resultados

Resultados cuantitativos

Presentación de resultados en forma de tablas y métricas.

Resultados cualitativos

Análisis de ejemplos representativos y comportamiento del sistema.

6.1.2. Discusión

Interpretación de resultados

Análisis crítico de los resultados obtenidos.

Limitaciones

Discusión sobre las limitaciones del enfoque propuesto.

6.2. Experimento 2...

7. CONCLUSIONES

7.1. Resumen de aportaciones

Síntesis de los principales resultados y contribuciones.

7.2. Respuesta a las preguntas de investigación

Evaluación de los resultados en relación con los objetivos planteados.

7.3. Trabajo futuro

Posibles líneas de investigación y mejoras del sistema desarrollado.

ANEXO X